UNIVERZITET U NOVOM SADU
FAKULTET TEHIČKIH NAUKA U NOVOM SADU

Andrijana Milijančević

Detekcija objekata

Detekcija objekata automobila

Novi Sad, 2026.

SADRŽAJ

1. Uvod 3
2. Pregled literature i postojećih pristupa 4
3. Najčešće korišćeni algoritmi i modeli 9
   3.1 Pregled algoritma i modela 9
   3.2 Metrike uspešnosti 10
4. Komentar i ideje studenta 11
5. Literatura 14

1. Uvod

Detekcija oblika automobila predstavlja jednu od ključnih oblasti u savremenom računarstvu i veštačkoj inteligenciji, posebno u kontekstu **računarskog vida** i **autonomnih sistema vožnje**. Cilj ovog zadatka je da se razviju algoritmi koji mogu da prepoznaju i precizno lokalizuju vozila na slikama ili video zapisima, uz mogućnost razlikovanja njihovih kontura i oblika. Takvi sistemi imaju široku primenu: od **bezbednosti u saobraćaju**, preko **inteligentnih transportnih sistema**, pa sve do **analize saobraćajnih tokova** i **urbanog planiranja** [1].

Osnovni izazovi u detekciji automobila proizilaze iz **varijabilnosti u realnom okruženju**: različiti tipovi vozila (automobili, kamioni, autobusi), promene osvetljenja (dan/noć), vremenski uslovi (kiša, magla, sneg), kao i zaklanjanje objekata i kompleksne urbane scene. Pored toga, algoritmi moraju da balansiraju između **tačnosti** i **brzine obrade**, jer se u realnim aplikacijama (npr. autonomna vožnja) zahteva **real-time performansa** [2].

Tokom poslednje decenije, razvoj **dubokih konvolutivnih neuronskih mreža (CNN)** značajno je unapredio mogućnosti detekcije i segmentacije vozila. Modeli kao što su **YOLO (You Only Look Once)** [3], **Faster R-CNN** [4], **SSD (Single Shot Detector)** [5] itd postali su standardni pristupi u ovoj oblasti.

2. Pregled literature i postojećih pristupa

Razvoj detekcije oblika automobila u okviru računarskog vida prošao je kroz nekoliko značajnih faza, od klasičnih metoda zasnovanih na ručno definisanim karakteristikama do savremenih pristupa utemeljenih na dubokim neuronskim mrežama. U ranim istraživanjima, algoritmi poput HOG (Histogram of Oriented Gradients) [6] i SIFT (Scale-Invariant Feature Transform) [7] koristili su se za izdvajanje vizuelnih karakteristika vozila, ali su pokazali ograničene performance.

HOG se koristi u računarskom vidu i obradi slika za detekciju objekata. On beleži strukturu ili oblik objekta analizirajući distribuciju (histograme) gradijentnih orijentacija u lokalizovanim delovima slike. HOG je posebno popularan za detekciju ljudi i vozila [6].

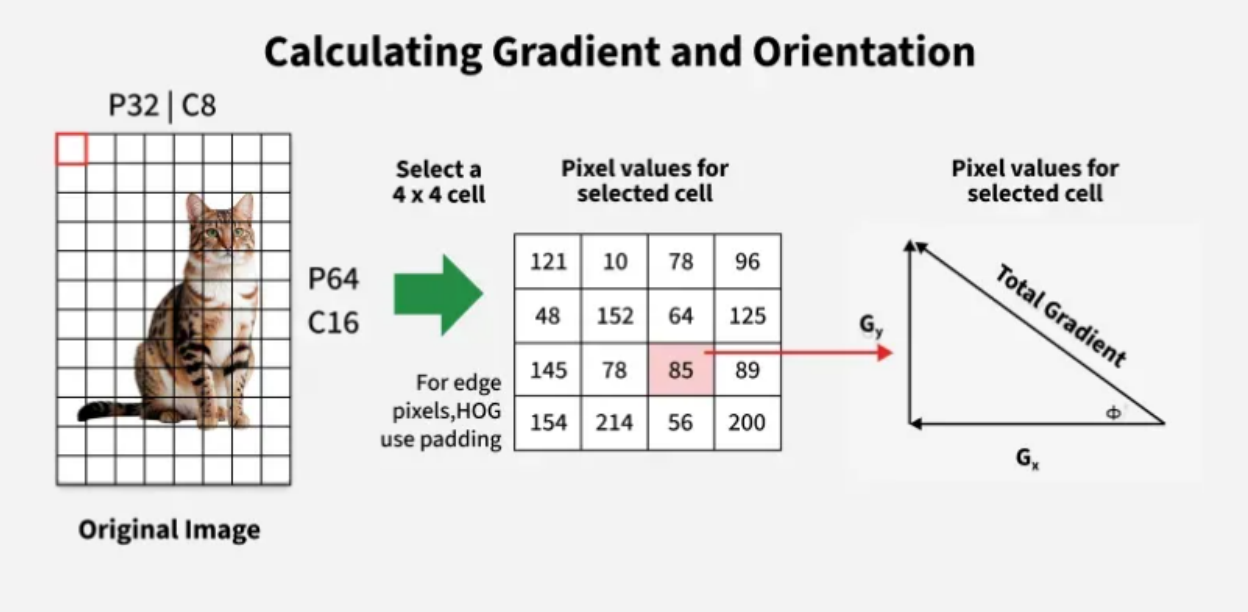

Slika 1: Proces računanja gradijenta i orijentacije u HOG algoritmu

Transformacija karakteristika invarijantnih u odnosu na skalu (SIFT) je važan algoritam u računarskom vidu koji pomaže u otkrivanju i opisivanju karakterističnih karakteristika na slikama. Predstavio ga je Dejvid Lou 1999. godine, a koristi se za mnoge važne zadatke u ovoj oblasti, uključujući prepoznavanje objekata, spajanje slika i 3D rekonstrukciju. Ističe se jer otkriva karakteristike koje su stabilne i konzistentne čak i kada slika prolazi kroz transformacije kao što su skaliranje, rotacija i promene uslova osvetljenja [7].

Sa pojavom konvolutivnih neuronskih mreža (CNN), došlo je do revolucionarnog pomaka u oblasti detekcije objekata. R-CNN predstavlja prvi uspešan pokušaj primene dubokih neuronskih mreža za detekciju objekata. R-CNN počinje deljenjem ulazne slike na više regiona ili podregiona. Ovi regioni se nazivaju „predlozi regiona“ ili „kandidati za region“. Korak predlaganja regiona je odgovoran za generisanje skupa potencijalnih regiona na slici koji verovatno sadrže objekte. R-CNN ne generiše ove predloge sam; umesto toga, oslanja se na spoljne metode poput selektivne pretrage ili EdgeBox-ova za generisanje predloga regiona.

Svaki region se zasebno izrezuje, skalira na fiksnu veličinu i prosleđuje kroz CNN koji izvlači obeležja. Na osnovu tih obeležja vrši se klasifikacija objekta. Pored klasifikacije objekata, R-CNN takođe vrši regresiju bounding box-a. Mane su mu sporost, velika potrošnja memorije i složen proces treniranja.

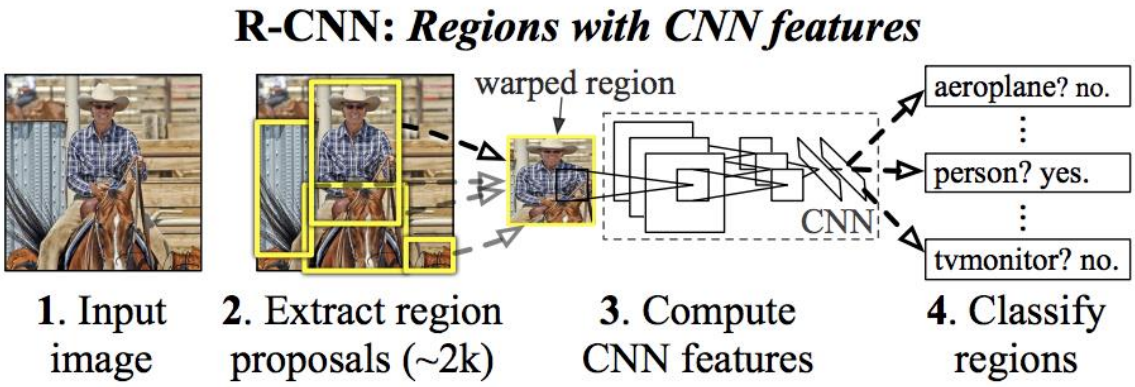

Slika 2: Proces detekcije objekata pomoću R-CNN algoritma

Faster R-CNN je popularan model dubokog učenja koji se koristi za detekciju objekata, a koji podrazumeva identifikaciju i lokalizaciju objekata unutar slike. Nadovezujući se na ranije modele poput R-CNN, Faster R-CNN je uveo značajno poboljšanje uključivanjem Region Proposal Network (RPN) koja generiše predloge objekata direktno unutar modela. Ova integracija ga čini bržim i preciznijim, omogućavajući mu da detektuje više objekata u realnom vremenu sa velikom preciznošću.

Za razliku od starijih metoda koje su trošile puno vremena na traženje objekata pomoću spoljnih programa, Faster R-CNN sve obavlja unutar jedne pametne mreže. On radi u dva koraka: prvo brzo skenira sliku da označi mesta gde bi mogli biti objekti, a zatim te delove pažljivo proverava da bi tačno odredio šta se na slici nalazi.

Da bi bio što precizniji, model koristi takozvane **anchor boxes**. To su unapred definisani pravougaonici različitih veličina i oblika koji mu pomažu da lakše prepozna i male objekte u daljini i velike objekte blizu kamere. Iako je zbog ovog detaljnog pristupa nešto sporiji od modela kao što je YOLO, on je i dalje prvi izbor kada je najvažnija maksimalna preciznost u prepoznavanju detalja.

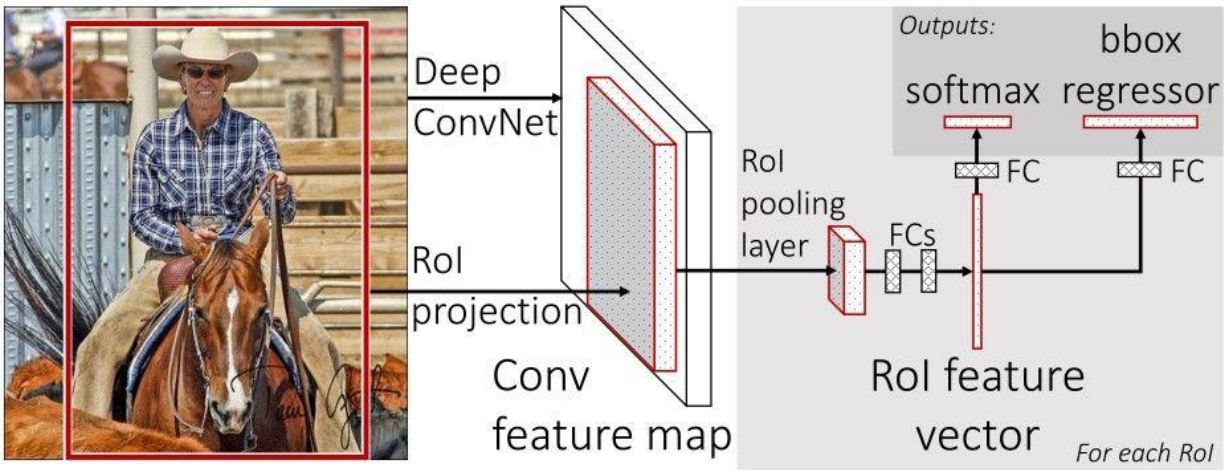

Slika 3: Fast R-CNN arhitektura za detekciju objekata

SSD (Single Shot MultiBox Detector) je model koji je uneo revoluciju u brzinu detekcije tako što je potpuno eliminisao potrebu za posebnim korakom predlaganja regiona. On funkcioniše u jednom prolazu kroz mrežu („Single Shot“), gde istovremeno predviđa i koordinate okvira i klasu objekta. Glavna karakteristika koja SSD izdvaja je korišćenje **višeskalnih mapa karakteristika** (multi-scale feature maps). To znači da model koristi različite slojeve neuronske mreže za detekciju: početni slojevi sa većom rezolucijom su zaduženi za pronalaženje malih objekte u daljini, dok dublji slojevi prepoznaju krupnije objekte bliže kameri. Ovakav pristup mu omogućava da postigne odličnu brzinu obrade uz solidnu preciznost, što ga čini jednim od najčešće korišćenih modela u sistemima gde je potreban rad u realnom vremenu na video snimcima saobraćaja.

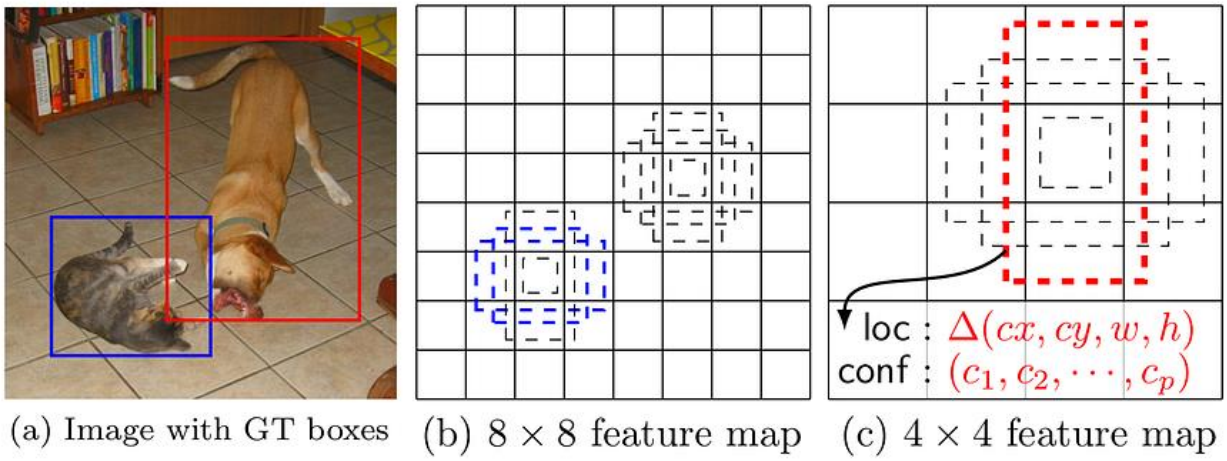

Slika 4: SSD arhitektura za detekciju objekata

YOLO (You Only Look Once) je jedan od najuticajnijih modela za detekciju objekata, koji su predložili Džozef Redmon i saradnici 2015. godine. Njegov razvoj bio je motivisan problemima tadašnjih modela, poput Fast R-CNN-a, koji je zahtevao 2–3 sekunde da obradi jednu sliku, pa nije bio pogodan za primenu u realnom vremenu. YOLO je doneo ključnu inovaciju – umesto višestepenih procesa, koristi se **jedan prolaz unapred kroz mrežu** da bi se dobila konačna predviđanja. Na taj način YOLO transformiše problem detekcije objekata u zadatak regresije, gde se direktno predviđaju bounding box-ovi i klase objekata.

Arhitektonski, YOLO deli ulaznu sliku na mrežu (grid), a svaka ćelija mreže predviđa bounding box-ove i njihove verovatnoće. Ovaj pristup omogućava **brzu i efikasnu detekciju** sa performansama od preko 30 slika u sekundi, što ga čini pogodnim za aplikacije u realnom vremenu, poput autonomne vožnje i sistema asistencije vozaču. Glavna prednost YOLO-a je brzina, dok su ograničenja slabija detekcija manjih objekata i scena sa velikim zaklanjanjem. Uprkos tome, YOLO je postao sinonim za realtime detekciju i kroz svoje verzije (YOLOv2, YOLOv3, YOLOv4, YOLOv5, YOLOv8) nastavio da unapređuje balans između tačnosti i brzine.

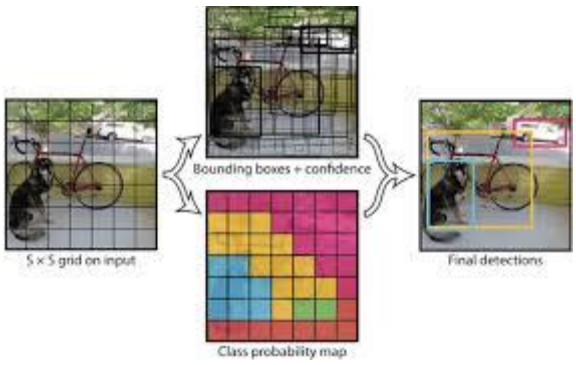

Slika 5: YOLO arhitektura za detekciju objekata

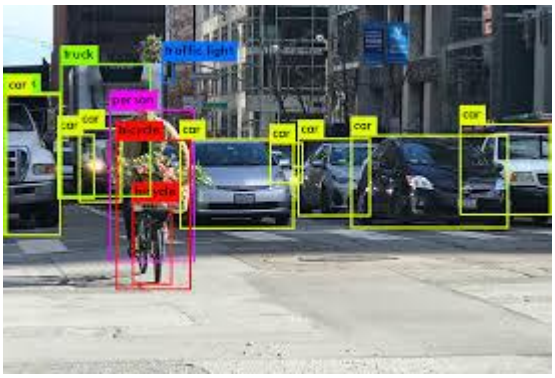

Slika 6: YOLO arhitektura za detekciju objekata

RetinaNet je jednostepeni model za detekciju objekata koji je predstavljen 2017. godine od strane istraživača iz Facebook AI Research (FAIR). Njegova ključna inovacija je uvođenje *Focal Loss* funkcije, koja rešava problem velikog disbalansa između pozadinskih i objektnih primera tokom treniranja. Kod jednostepenih detektora, većina *anchor box-ova* pripada pozadini, dok je broj pozitivnih primera mali, pa model često nauči da predviđa pozadinu, ali slabije prepoznaje stvarne objekte. Focal Loss smanjuje doprinos lako klasifikovanih negativnih primera i fokusira učenje na teške i retke pozitivne primere, čime se postiže znatno bolja preciznost u poređenju sa SSD i ranim YOLO verzijama. Prednost RetinaNet-a je odličan balans između preciznosti i jednostavnosti, pa se često koristi kao referentni model u istraživanjima i sistemima gde je tačnost važnija od brzine. Njegovo ograničenje je sporija inferencija u poređenju sa YOLO modelima, zbog čega se ređe primenjuje u real-time aplikacijama.

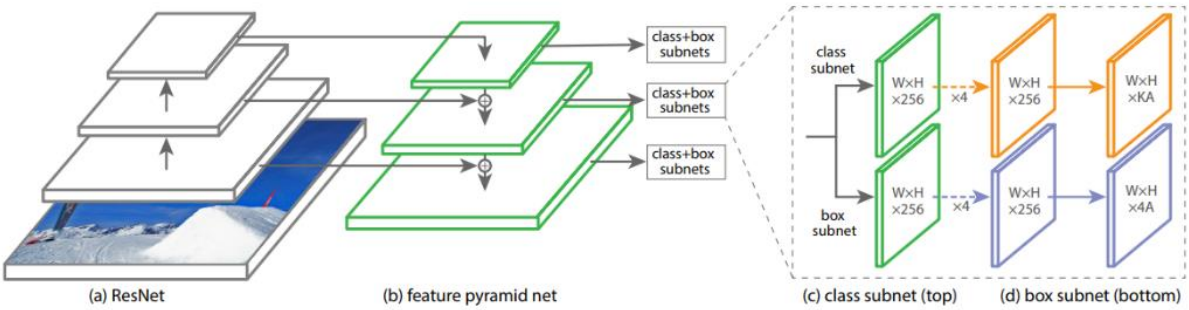

Slika 7: RetinaNet model

EfficientDet je moderan algoritam za detekciju objekata koji je predstavljen 2020. godine od strane istraživača sa Google-a. Njegova glavna ideja je da obezbedi **skalabilnu arhitekturu** koja se može prilagoditi različitim scenarijima – od mobilnih uređaja sa ograničenim resursima do visoko-preciznih sistema u cloudu. EfficientDet koristi **BiFPN (Bidirectional Feature Pyramid Network)**, koja omogućava ponovljeno i dvosmerno spajanje feature mapa (odozgo-nadole i odozdo-nagore), čime se postiže bolje iskorišćavanje informacija o malim i velikim objektima. Model se trenira end-to-end i dolazi u porodici verzija (D0–D7), gde se sistematski povećavaju dubina, širina i rezolucija mreže.

Glavne prednosti EfficientDet-a su odličan balans između brzine i tačnosti, kao i mogućnost skaliranja u zavisnosti od primene. Pogodan je za deployment u realnim sistemima, jer omogućava da se isti koncept koristi i na mobilnim uređajima i na serverima. Njegova mana je veća arhitektonska kompleksnost u poređenju sa YOLO modelima, kao i zahtevnije treniranje. Uprkos tome, EfficientDet se smatra jednim od najefikasnijih modela za detekciju objekata u savremenim aplikacijama.

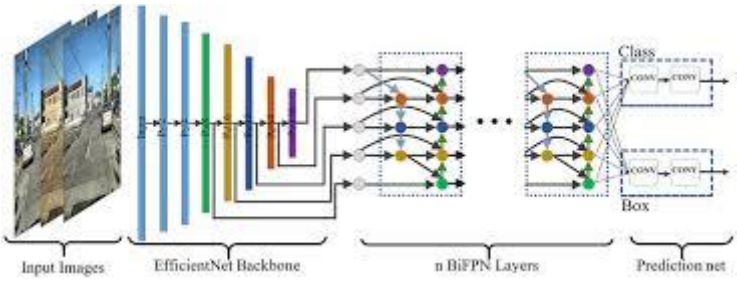

Slika 8: EfficientDet algoritam

PointPillars je algoritam za 3D detekciju objekata razvijen prvenstveno za potrebe autonomne vožnje. Njegova osnovna ideja je da se LiDAR podaci, koji dolaze u obliku point cloud-a (skup tačaka u prostoru), transformišu u tzv. *stubove* (pillars). Svaki stub grupiše tačke u vertikalne kolone, a zatim se enkodira pomoću PointNet mreže kako bi se izvukle značajne karakteristike. Te enkodirane informacije se dalje raspoređuju u 2D mrežu, stvarajući *pseudo-sliku* koja se može obraditi standardnim 2D konvolucionim neuronskim mrežama. Na taj način PointPillars izbegava skupe 3D konvolucije, postiže visoku brzinu obrade i omogućava realtime performanse. Prednost ovog pristupa je balans između tačnosti i efikasnosti, što ga čini pogodnim za detekciju vozila i drugih objekata u saobraćaju. Glavno ograničenje je zavisnost od LiDAR senzora i gubitak dela prostorne informacije prilikom transformacije u 2D, ali u praksi PointPillars predstavlja jedno od najčešće korišćenih rešenja u modernim sistemima autonomne vožnje [10].

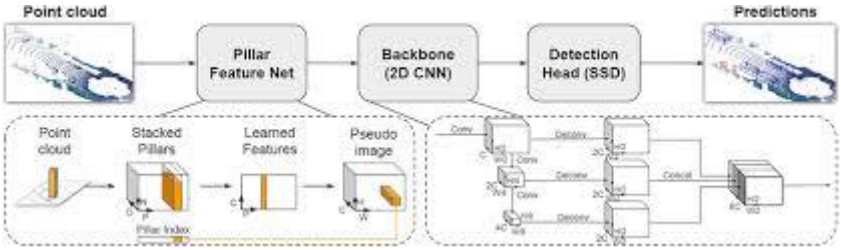

Slika 9: PointPillars algoritam

3. Najčešće korišćeni algoritmi i modeli

3.1 Pregled algoritma i modela

U prethodnom poglavlju smo objasnili većinu algoritama, u ovom poglavlju ćemo napraviti njihov pregled :

1. **Klasične metode (pre CNN-a)**

- **HOG (Histogram of Oriented Gradients)** – izdvajanje ivica i kontura vozila.
- **SIFT (Scale-Invariant Feature Transform)** – robustan na promene skale i rotacije.
- Ograničenje: slabe performanse u realnim uslovima (osvetljenje, zaklanjanje).

2. **CNN-based detektori**

- **YOLO (You Only Look Once)**
    - Jednostepeni detektor, realtime performanse (30+ FPS).
    - Prednost: brzina.
    - Ograničenje: slabija detekcija malih objekata.
- **Faster R-CNN**
    - Dvostepeni pristup (region proposal + klasifikacija).
    - Prednost: visoka tačnost.
    - Ograničenje: spor, zahteva resurse.
- **SSD (Single Shot MultiBox Detector)**
    - Višeslojna mreža za bounding boxove na različitim skalama.
    - Prednost: balans brzine i tačnosti.
    - Ograničenje: slabija detekcija manjih objekata.
- **RetinaNet (2017)**
    - Jednostepeni detektor sa **Focal Loss** funkcijom.
    - Rešava problem disbalansa između pozadine i objekata tokom treniranja.
    - Arhitektura: CNN backbone (najčešće ResNet) + Feature Pyramid Network (FPN).
    - Prednost: odličan balans između preciznosti i jednostavnosti.
    - Ograničenje: sporiji od YOLO-a, manje pogodan za realtime sisteme.
- **EfficientDet (2020)**
    - Koristi **BiFPN** (bidirekciono spajanje feature mapa) i skalabilnu porodicu modela (D0–D7).
    - Prednost: balans brzine i tačnosti, skalabilnost od mobilnih uređaja do cloud sistema.
    - Ograničenje: veća arhitektonska kompleksnost i zahtevnije treniranje.

3. **3D detekcija (za autonomnu vožnju)**

- **PointPillars** – koristi LiDAR podatke za procenu udaljenosti i položaja vozila.
- Prednost: omogućava prostornu analizu.
- Ograničenje: zavisi od dodatnih senzora.

3.2 Metrike uspešnosti

Metrike uspešnosti su ključni alati za procenu tačnosti i efikasnosti modela za detekciju objekata. One bacaju svetlo na to koliko efikasno model može da identifikuje i lokalizuje objekte unutar slika. Pored toga, pomažu u razumevanju načina na koji model rukuje lažno pozitivnim i lažno negativnim rezultatima. Ovi uvidi su ključni za procenu i poboljšanje performansi modela.

U nastavku ćemo pomenuti najbitnije i najkorišćenije metrike:

- **Intersection over Union (IoU)**: IoU je mera koja kvantifikuje preklapanje između predviđenog bounding box-a i stvarnog (ground truth) bounding box-a. Ona ima fundamentalnu ulogu u evaluaciji tačnosti lokalizacije objekata.
- **Average Precision (AP):** AP računa površinu ispod precision-recall krive, pružajući jednu vrednost koja obuhvata performanse modela u pogledu preciznosti i odziva.
- **Mean Average Precision (mAP):** mAP proširuje koncept AP-a tako što izračunava prosečne AP vrednosti preko više klasa objekata. Ovo je korisno u scenarijima detekcije sa više klasa, jer daje sveobuhvatnu evaluaciju performansi modela.
- **Precision i Recall:** Precision kvantifikuje udeo tačnih pozitivnih predikcija u odnosu na sve pozitivne predikcije, procenjujući sposobnost modela da izbegne lažno pozitivne rezultate. Recall, s druge strane, računa udeo tačnih pozitivnih predikcija u odnosu na sve stvarne pozitivne primere, mereći sposobnost modela da detektuje sve instance jedne klase.
- **F1 Score:** F1 Score je harmonijska sredina između precision-a i recall-a, pružajući uravnoteženu procenu performansi modela uzimajući u obzir i lažno pozitivne i lažno negativne rezultate.

4. Komentar i ideje studenta

Analizom dosadašnjih rešenja uočila sam da glavni problem u detekciji automobila nije samo preciznost, već preciznosti sa brzinom obrade. Većina kompleksnih modela presporo obrađuje slike, što ih čini neupotrebljivim za sisteme koji moraju da reaguju trenutno. Zato je moja vizija primena **YOLO** arhitekture, jer ona detekciju rešava u jednom koraku, čime se štedi procesorska snaga i omogućava prepoznavanje vozila bez kašnjenja.

Plan rada se zasniva na korišćenju dodeljenog skupa podataka koji planiram da pripremim tako da model bude što efikasniji. Glavna ideja je da kroz trening postignem stabilnost sistema, kako bi on mogao da prepozna vozilo čim se pojavi u kadru.

Kao krajnji cilj vidim razvoj rešenja koje je pre svega praktično i upotrebljivo. Želim da postignem visoku preciznost, ali tako da sistem ostane dovoljno lagan za pokretanje na standardnom hardveru.

Najveći izazovi u nastavku biće detekcija u lošim uslovima, kao što su mrak, jaka kiša ili magla, gde su konture automobila slabije vidljive. Takođe, prepoznavanje vozila koja su skoro potpuno zaklonjena drugim objektima biće težak zadatak za model. Rešavanje ovih prepreka biće glavni fokus u sledećim fazama projekta kako bi sistem bio pouzdan u svim realnim situacijama.

5. Zaključak

5.1. Analiza skupa podataka i pretprocesiranje

Eksperiment je sproveden na namenskom skupu podataka rezolucije **676x380** piksela. Iako inicijalni dataset sadrži više slika, za finalni razvoj i finu kalibraciju modela korišćen je balansirani skup od **390 slika**. Struktura je pažljivo planirana: **355 slika sa vozilima** i **35 pozadinskih slika (10%)** koje ne sadrže automobile. Uvođenje ovih "praznih" slika je ključni korak jer uči model da ignoriše pozadinu npr senke i drveće, čime se drastično smanjuju lažne detekcije. Podaci su podeljeni u odnosu 80/10/10 za trening, validaciju i finalni test.

Sve slike su normalizovane na opseg [0, 1] i skalirane na 640 X 640 piksela pre ulaska u mrežu. Kako bi se sprečilo overfitting, primenjena je **Mosaic augmentacija** koja spaja četiri različite slike u jednu, primoravajući model da prepoznaje automobile čak i kada su delimično zaklonjeni ili isečeni ivicom kadra.

5.2. Baseline model vs Napredni model

U početnoj fazi razvijen je **Baseline CNN** model za binarnu klasifikaciju. Iako je postigao ukupnu tačnost od oko **72%**, detaljna analiza je pokazala nizak odziv (**Recall 38%**). To znači da je osnovni model bio "slep" za više od polovine automobila, posebno onih u daljini. Glavno ograničenje je bilo to što je model mogao samo da kaže da li auto postoji, ali ne i gde se on nalazi.

Prelaskom na **YOLOv8s** arhitekturu u CP3 fazi, problem je rešen uvođenjem objektne detekcije. YOLOv8s posmatra sliku kao jedinstven regresioni problem, predviđajući klase i precizne koordinate (bounding boxes) u jednom prolazu kroz mrežu.

5.3. Prikaz i tumačenje rezultata

Nakon 50 epoha treninga uz primenu *Transfer Learning-a*, postignuti su sledeći rezultati na testnom skupu:

Metrika	Vrednost	Interpretacija
mAP50	**0.9650**	Precizna lokalizacija i iscrtavanje okvira.
Precision	**0.9576**	Preko 95% detekcija su zaista automobili.
Recall	**0.9328**	Sistem uspešno pronalazi 93% svih vozila na slici.
Inference	**~2.4 ms**	Ekstremna brzina, omogućava rad od preko 100 FPS.

Metrike uspešnosti nedvosmisleno ukazuju na to da je model **stabilan i validan** za inženjersku primenu.

- **Dobre strane :** Model je pokazao izuzetnu otpornost na preklapanje objekata (okluziju) zahvaljujući **Mosaic augmentaciji**. Takođe, uvođenje 10% pozadinskih slika je "naučilo" model da ne pravi greške na praznim putevima, što je ranije bio glavni uzrok lažnih uzbuna. Overfitting je uspešno izbegnut, što potvrđuje usklađenost trening i validacionih kriva.
- **Slabosti i ograničenja:** Iako je recall visok, glavno ograničenje ostaju **veoma mali objekti u daljini**. Zbog rezolucije slike, ti objekti zauzimaju premalo piksela da bi ih neuronska mreža pouzdano izdvojila iz dubljih slojeva.

6. Literatura

[1] A. Geiger, P. Lenz, and R. Urtasun, *Are we ready for Autonomous Driving? The KITTI Vision Benchmark Suite*, Proc. CVPR, 2012.

[2] M. Cordts et al., *The Cityscapes Dataset for Semantic Urban Scene Understanding*, Proc. CVPR, 2016.

[3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, *You Only Look Once: Unified, Real-Time Object Detection*, Proc. CVPR, 2016.

[4] S. Ren, K. He, R. Girshick, and J. Sun, *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*, Advances in Neural Information Processing Systems (NeurIPS), 2015.

[5] W. Liu et al., *SSD: Single Shot MultiBox Detector*, Proc. ECCV, 2016.

[6] GeeksforGeeks, *Histogram of Oriented Gradients (HOG)*, dostupno na: https://www.geeksforgeeks.org/computer-vision/histogram-of-oriented-gradients/

[7] GeeksforGeeks, *Scale-Invariant Feature Transform (SIFT)*, dostupno na: https://www.geeksforgeeks.org/computer-vision/describe-the-concept-of-scale-invariant-feature-transform-sift/

[8] Roboflow Blog, *What is R-CNN?*, dostupno na: https://blog.roboflow.com/what-is-r-cnn/

[9] Medium, *Single Shot MultiBox Detector (SSD) Explained*, dostupno na: https://medium.com/@jesse419419/single-shot-multibox-detector-ssd-explained-by-a-j-dda10ba42a29

[10] CodeGenes, *PointPillars PyTorch Implementation*, dostupno na: https://www.codegenes.net/blog/pointpillars-pytorch/